

Klasyfikacja gatunków muzycznych na podstawie cech audio

Porównanie cech obliczanych biblioteką
librosa z embeddingiem pretrenowanego
modelu

Jakub Karczewski

Projekt eksploracji danych

2026

Pytanie

Czy ręcznie obliczane cechy audio z biblioteki librosa są wystarczające do klasyfikacji gatunku muzycznego, czy lepszą reprezentację daje embedding z modelu pretrained?

- Problem: wieloklasowa klasyfikacja 8 gatunków muzycznych.
- Dane wejściowe: tylko sygnał audio, bez tekstu, wykonawcy ani metadanych opisowych.
- Porównanie obejmuje trzy notebooki eksperymentalne oraz modele klasyfikacyjne trenowane na tych samych etykietach.

Zbiór danych: FMA Small



- Free Music Archive, wariant **FMA Small**.
- Około **8000 utworów**.
- Oryginalny podział FMA na zbiór treningowy oraz walidacyjno-testowy.
- W eksperymencie z embeddingami: 6400 utworów treningowych, z czego 6 odrzucono przez błędy przetwarzania; 1600 utworów walidacyjno-testowych.


Gatunki

Electronic, Experimental, Folk, Hip-Hop, Instrumental, International, Pop, Rock

Porównywane reprezentacje audio

Eksperyment	Strategia cech	Liczba cech	Reprezentacja
librosa 70	librosa, zestaw zredukowany	70	MFCC, chroma, RMS, centroid, ZCR
librosa 518	librosa, zestaw rozszerzony	518	szerszy zestaw deskryptorów i statystyk
Cnn14/PANNs	embedding modelu pretrained	2048	PANNs/Cnn14 przez panns_inference

Pipeline eksperymentalny



- Dla cech librosa zastosowano StandardScaler; testowano PCA do 4 komponentów oraz wariant bez PCA.
- Dla embeddingów Cnn14 zastosowano normalizację L2; PCA zachowujące 95% wariancji dało 182 komponenty.

Modele

- SVM: kernel liniowy i RBF
- Random Forest
- LightGBM
- Logistic Regression

Metryki

- Accuracy na zbiorze testowym
- Macro F1
- Raporty precision/recall/F1
- Macierze pomyłek

Wyniki: librosa, 70 cech

Reprezentacja	Model	Train acc.	Test acc.	Macro F1
PCA, 4 komponenty	SVM liniowy	0.342	0.339	0.31
PCA, 4 komponenty	Random Forest	0.452	0.329	0.31
Bez PCA	Random Forest	0.598	0.438	0.42
Bez PCA	SVM RBF	0.506	0.446	0.43
Bez PCA	LightGBM	0.738	0.444	0.44
Bez PCA	Logistic Regression	0.506	0.394	0.39

- Najlepszy wynik accuracy: około **44.6%**.
- PCA do 4 komponentów znacząco pogarsza jakość klasyfikacji.

Wyniki: librosa, 518 cech

Reprezentacja	Model	Train acc.	Test acc.	Macro F1
PCA, 4 komponenty	SVM liniowy	0.340	0.317	0.27
PCA, 4 komponenty	Random Forest	0.436	0.324	0.31
Bez PCA	Random Forest	0.653	0.460	0.44
Bez PCA	SVM RBF	0.441	0.411	0.39
Bez PCA	LightGBM	0.844	0.472	0.47
Bez PCA	Logistic Regression	0.705	0.449	0.45

- Rozszerzenie liczby cech z 70 do 518 poprawia wynik, ale umiarkowanie: z 44.6% do 47.2%.
- LightGBM osiąga najlepszy wynik, lecz różnica train/test wskazuje na przeuczenie.


Wyniki: embeddingi pretrained

Reprezentacja	Model	Train acc.	Test acc.	Macro F1 / wynik
2048-d, L2, bez PCA	LightGBM	–	0.610	0.610
PCA, 182 komponenty	LightGBM	0.817	0.599	0.595
PCA, 182 komponenty	Log. Regression	0.672	0.611	0.610
PCA, 182 komponenty	Random Forest	0.998	0.603	CV macro F1: 0.631

- Najlepszy wynik testowy: **61.1% accuracy** dla regresji logistycznej.
- Prosty model liniowy działa dobrze, ponieważ embedding zawiera bogatszą reprezentację dźwięku.

Porównanie najlepszych konfiguracji

Konfiguracja	Test accuracy	Macro F1	Różnica
Najlepszy wariant librosa, 70 cech	0.446	0.43	punkt odniesienia najlepsze librosa
Najlepszy wariant librosa, 518 cech	0.472	0.47	
Najlepszy wariant embeddingów	0.611	0.610	+0.139 względem full librosa



- Ręcznie obliczane cechy librosa dają sensowny baseline, ale ich najlepszy wynik pozostaje poniżej 50% accuracy.
- Większy zestaw cech librosa poprawia jakość, ale nie usuwa ograniczenia wynikającego z niskopoziomowego opisu sygnału.
- Embedding Cnn14 powstał w wyniku uczenia na dużym zadaniu audio-taggingu, więc przenosi informację o barwie, instrumentacji, rytmie i strukturze czasowo-częstotliwościowej.
- Wariant pretrained poprawia accuracy o około **13.9 punktu procentowego** względem najlepszego wariantu librosa.

Zachowanie na poziomie gatunków

Najczęściej prawidłowo przewidywane klasy

- Rock
- Hip-Hop
- Electronic

Najtrudniejsza do poprawnego przypisania klasa

- Pop

Typowe pomyłki: Rock vs Pop, Folk vs International, Electronic vs Experimental oraz Instrumental vs Folk/International. Wynika to z nakładania się cech akustycznych między gatunkami.

- 1 Cechy librosa są interpretowalne i tanie obliczeniowo, ale mają ograniczoną zdolność separowania gatunków.
- 2 PCA do 4 komponentów w eksperymentach librosa usuwa zbyt dużo informacji.
- 3 Embeddingi pretrained są wyraźnie skuteczniejsze: najlepsze accuracy rośnie z 47.2% do 61.1%.
- 4 Najbardziej praktyczny wariant w tych eksperymentach to embedding Cnn14 + PCA 95% + Logistic Regression.

Wniosek ogólny

Dla klasyfikacji gatunków muzycznych transfer learning daje znacznie bogatszą reprezentację niż same ręcznie projektowane deskryptory audio.

-  M. Defferrard, K. Benzi, P. Vandergheynst, X. Bresson, *FMA: A Dataset For Music Analysis*, 2017.
-  Free Music Archive dataset repository:
<https://github.com/mdeff/fma>
-  Librosa documentation: <https://librosa.org>
-  Scikit-learn documentation: <https://scikit-learn.org>
-  LightGBM documentation: <https://lightgbm.readthedocs.io>
-  Q. Kong et al., *PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition*.